Klasifikacija muzike na osnovu žanra

Tamara Krstic 96/2022
Natalija Pavlicevic 68/2022

OPIS PROBLEMA

- Problem klasifikacije žanrova je specifičan jer su granice između žanrova često subjektivne i prožimaju se.
- Za razliku od klasifikacije slika gde su objekti jasno definisani, muzički žanr je određen kombinacijom ritma, harmonije, instrumentacije i teksture zvuka.
- Cilj ovog rada je razvoj i evaluacija modela mašinskog učenja koji na osnovu digitalnog audio signala dodeljuje jednu od deset unapred definisanih kategorija (žanrova).

- U ovom radu koristi se **GTZAN** skup podataka, koji se u naučnoj zajednici smatra "benchmark" skupom za ovu vrstu problema. Ovaj skup sadrži 1000 audio numera podeljenih u 10 žanrova (Blues, Classical, Country, Disco, Hiphop, Jazz, Metal, Pop, Reggae, Rock).

- Rana istraživanja u ovoj oblasti fokusirala su se na ekstrakciju ručno definisanih karakteristika (eng. *hand-crafted features*)
- Najnovija istraživanja, poput onog koje su sproveli Setiorini i saradnici (2025), ukazuju na to da kombinacija konvolutivnih i rekurentnih slojeva (CRNN) daje vrhunske rezultate na GTZAN skupu podataka
- Fokus je stavljen na bazni MLP model kako bi se ispitala linearna separabilnost MFCC obeležja pre primene kompleksnijih arhitektura.
- Pored toga, implementiran je i konvolucioni neuronski model (CNN) nad Mel-spektrogramima radi ispitivanja sposobnosti dubokih arhitektura da automatski ekstraktuju prostorno-vremenske karakteristike audio signala i unaprede performanse klasifikacije

METODOLOGIJA

MLP pristup:

1) Učitavanje audio zapisa iz GTZAN skupa podataka
2) Pretprocesiranje signala/podataka
3) Ekstrakcija MFCC obeležja
4) Formiranje ulaznog vektora karakteristika
5) Obuka MLP klasifikatora
6) Evaluacija modela korišćenjem standardnih metrika

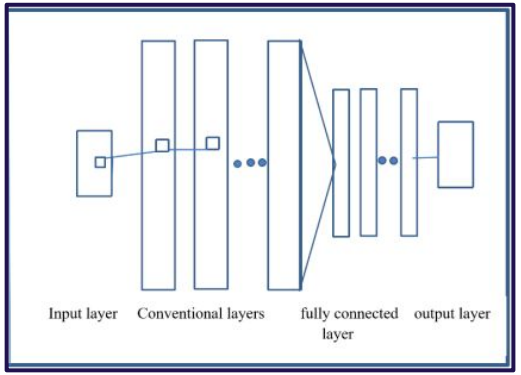

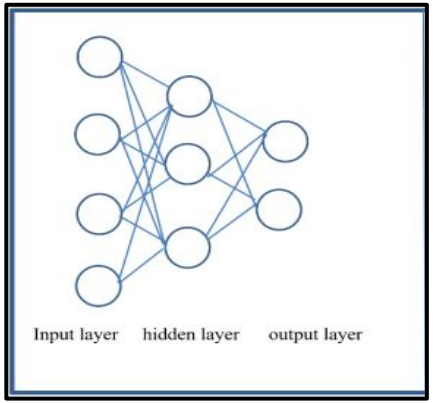

CNN pristup:

1) **Generisanje Mel-spektrograma**
2) **Pretprocesiranje i normalizacija**
3) **Definisanje arhitekture modela**
4) **Konfiguracija strategije obuke**
5) **Obuka modela**
6) **Evaluacija i vizuelizacija**

PRETPROCESIRANJE PODATAKA

- Pre obuke modela mašinskog učenja neophodno je izvršiti adekvatnu obradu audio signala kako bi se obezbedila konzistentnost ulaznih podataka i stabilnost modela.
- Svi audio zapisi učitani su koristeći biblioteku Librosa uz fiksnu frekvenciju uzorkovanja od 22.050 Hz.
- Signal je zatim normalizovan kako bi se smanjio uticaj razlika u jačini zvuka između različitih numera.
- Iako su svi zapisi iste dužine, audio signal je podeljen na kraće vremenske prozore (frame-ove) radi ekstrakcije lokalnih vremensko-frekventnih karakteristika. Segmentacija omogućava precizniju analizu promena u spektralnoj strukturi tokom vremena.
- **Za CNN model (Spektrogramski pristup):** Umesto redukcije podataka na statističke deskriptore, generisani su kompletni Mel-spektrogrami.
  - Ova 2D reprezentacija čuva celokupnu vremensko-frekvencijsku strukturu signala, tretirajući audio zapis kao sliku visoke rezolucije, što omogućava konvolutivnim slojevima da detektuju kompleksne teksturne obrasce žanra.

Vizuelizacija audio signala:

- U okviru analize podataka izvršena je i vizualizacija audio signala u cilju boljeg razumevanja njihovih spektralnih karakteristika. Za ovu svrhu korišćeni su vremenski i vremensko-frekventni prikazi signala.
- Waveform predstavlja prikaz amplitude audio signala kroz vreme i omogućava analizu dinamičkih promena zvuka.
- Mel spektrogram predstavlja vremensko-frekventnu reprezentaciju signala zasnovanu na Mel skali, koja modeluje nelinearnu percepciju frekvencija kod ljudskog sluha.
- Vizualizacija je korišćena kao pomoćni alat za analizu razlika između muzičkih žanrova i za potvrdu spektralnih karakteristika relevantnih za klasifikaciju.

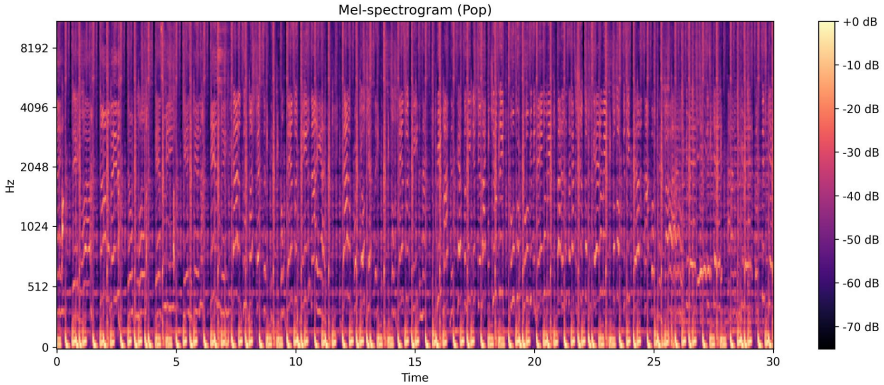

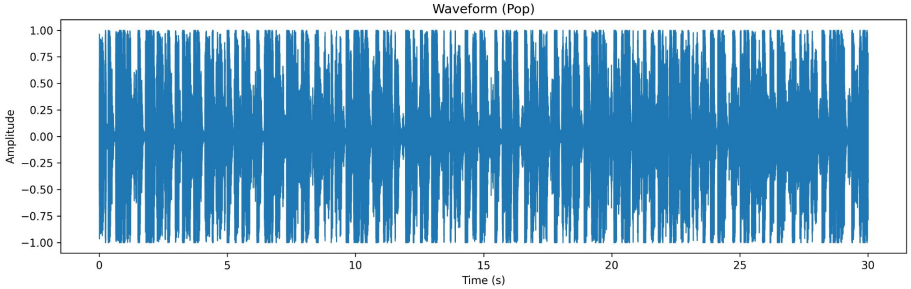

EKSTRAKCIJA OBELEŽJA

- Nakon faze pretprocesiranja audio signala, pristupa se ekstrakciji reprezentativnih obeležja koja omogućavaju efikasnu klasifikaciju muzičkih žanrova. Cilj ove faze je transformacija sirovog audio signala u kompaktnu numeričku reprezentaciju pogodnu za ulaz u model mašinskog učenja.
- MFCC predstavljaju standard u oblasti analize audio signala, jer omogućavaju efikasno modelovanje perceptivnih karakteristika zvuka.
- Proces izračunavanja MFCC obeležja sastoji se iz sledećih koraka:
    1) Primena kratkotrajne Furijeove transformacije (STFT) nad segmentiranim signalom.
    2) Mapiranje frekvencijskog spektra na Mel skalu pomoću Mel filter banke.
    3) Logaritamska transformacija energije po filterima.
    4) Diskretna kosinusna transformacija (DCT) radi dobijanja cepstralnih koeficijenata.

U implementaciji je korišćeno:

- ➢ Frekvencija uzorkovanja: 22.050 Hz
- ➢ Broj Mel filtera: 128
- ➢ Broj MFCC koeficijenata: 20

- ❑ Svaki audio zapis rezultuje matricom dimenzija: $N_{frames} \times N_{MFCC}$
- ❑ Izvršena je agregacija MFCC matrice po vremenskoj osi
- ❑ Na taj način formiran je ulazni vektor dimenzije: $2 \times N_{MFCC}$

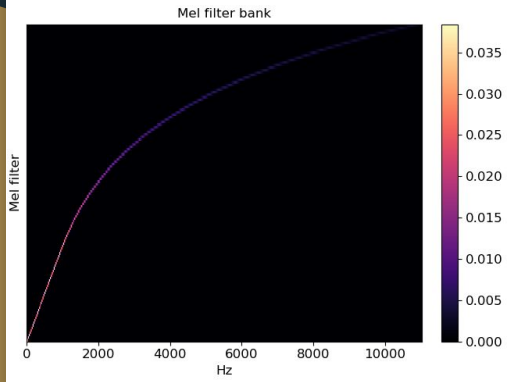

- ❑ MFCC obeležja su odabrana iz sledećih razloga:
  1) Dokazana efikasnost u klasifikaciji audio signala.
  2) Biološka utemeljenost kroz Mel skalu.
  3) Kompatibilnost sa jednostavnijim klasifikatorima poput MLP modela.
  4) Upotreba u savremenim istraživanjima, uključujući rad Setiorini i saradnika (2025)

- Za razliku od MLP modela koji koristi agregaciju (srednju vrednost i devijaciju), CNN model koristi sirovi Mel-spektrogram generisan u fazi pre DCT transformacije. Dok MFCC proces vrši kompresiju podataka radi jednostavnosti, za potrebe CNN modela zadržava se kompletna 2D matrica.

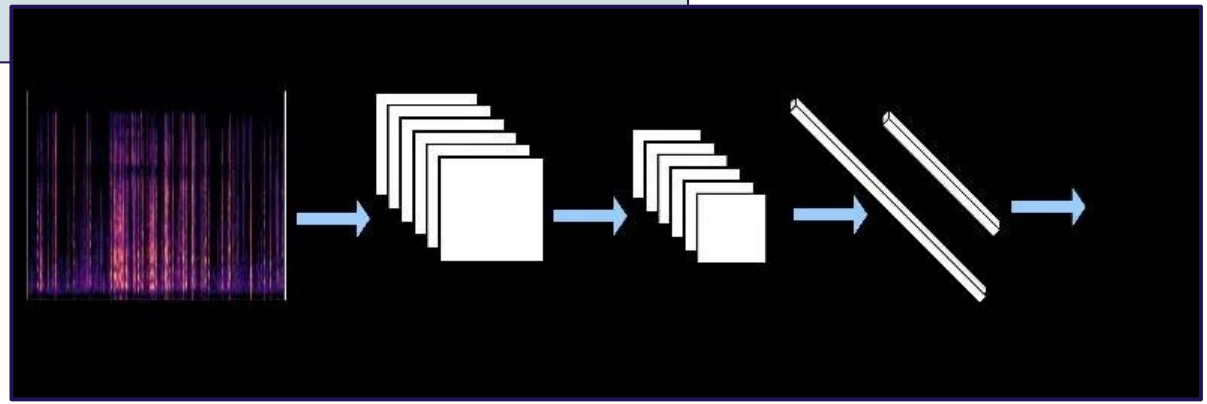

MLP VS CNN

TIP	ARHITEKTURA MODELA	OBUKA MODELA
MLP	Model se sastoji od četiri potpuno povezana sloja: • Ulazni sloj • Tri skrivena sloja sa ReLU aktivacionom funkcijom • Izlazni sloj sa Softmax aktivacijom	Adam optimizator i funkcije gubitka kategorijske unakrsne entropije (categorical crossentropy): $L=-\Sigma y \log(y)$ Treniran tokom 25 epoha sa veličinom batch-a od 32 uz korišćenje 10% trening podataka za validaciju.
CNN	Arhitektura se sastoji od: • **Tri konvolutivna bloka** • **Batch Normalization** • **MaxPooling2D** • **GlobalAveragePooling2D** • **Klasifikacioni deo**	**Adam optimizator** sa smanjenom stopom učenja (10^{-4}) kako bi se osigurala precizna konvergencija. Korišćena je funkcija gubitka *Sparse Categorical Crossentropy*, koja je pogodna za klasifikaciju gde su izlazne oznake celi brojevi.

EKSPERIMENTI I REZULTATI

- U cilju evaluacije performansi predloženog sistema izvršeno je eksperimentalno testiranje modela na test skupu podataka. Podaci su podeljeni na trening i test skup u odnosu 80:20, uz dodatno izdvajanje 10% trening podataka za validaciju.
- Matrice konfuzije :

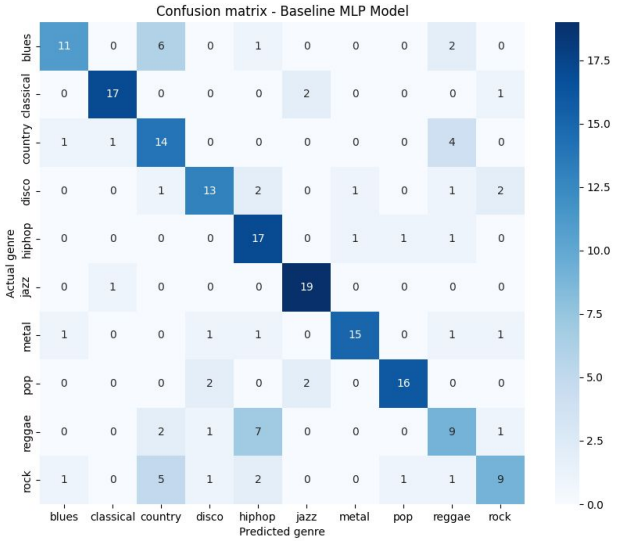

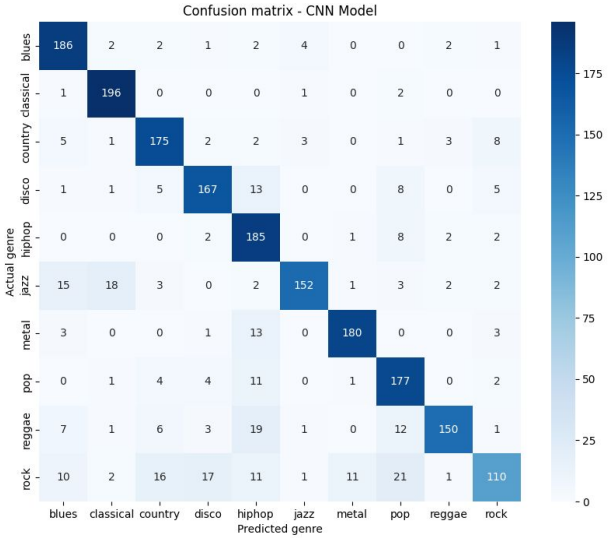

Rezultati MLP modela:

žanr	preciznost	odziv	f1-skor
blues	0.79	0.55	0.65
classical	0.89	0.85	0.87
country	0.50	0.70	0.58
disco	0.72	0.65	0.68
hiphop	0.57	0.85	0.68
jazz	0.83	0.95	0.88
metal	0.88	0.75	0.81
pop	0.89	0.80	0.84
reggae	0.47	0.45	0.46
rock	0.64	0.45	0.53

- Iz rezultata se jasno vidi da model nije podjednako uspešan za sve žanrove:
  - **Najuspešniji žanrovi:** Jazz (F1-score: 0.88) i Classical (F1-score: 0.87).
  - **Najveći izazovi:** Reggae (0.46) i Rock (0.53).
  - **Sličnost instrumenata:** Niska preciznost kod žanra Reggae (0.47) često je posledica mešanja sa žanrovima poput Hiphop-a
  - **Problem žanra Rock:** Rock muzika ima nizak odziv (recall) od samo 0.45, što znači da je model više od polovine pesama ovog žanra pogrešno klasifikovao u druge kategorije (najčešće Country).
  - **Hiphop:** Primećuje se da model ima visok odziv za Hiphop (0.85), ali nisku preciznost (0.57)

Rezultati CNN modela:

žanr	preciznost	odziv	f1-skor
blues	0.82	0.93	0.87
classical	0.88	0.98	0.93
country	0.83	0.88	0.85
disco	0.85	0.83	0.84
hiphop	0.72	0.93	0.81
jazz	0.94	0.77	0.84
metal	0.93	0.90	0.91
pop	0.76	0.82	0.82
reggae	0.94	0.75	0.83
rock	0.82	0.55	0.66

- **Najuspešniji žanrovi:** Model najbolje prepoznaje Metal (F1-score: 0.91) i Classical (F1-score: 0.93).
- **Klasa sa umerenim performansama:** Jazz ima visoku precision (0.94), ali niži recall (0.77). Model retko pogrešno označava druge žanrove kao jazz, ali deo jazz primera klasifikuje u srodne kategorije.
- **Najveći izazovi:** Najslabije rezultate model postiže kod žanra Rock (f1-skor 0.66, odziv: 0.55). Nizak odziv ukazuje na to da CNN model često klasifikuje rock pesme kao druge žanrove

Rezultati CRNN modela iz literature:

Dropout	Learning rate	Accuracy	Loss	Precision	Recall	F1 score
-	0.1	10.06%	230.86%	1.01%	10.06%	1.84%
-	0.01	74.07%	91.52%	74.82%	74.07%	73.81%
-	0.001	86.74%	64.69%	86.84%	86.74%	86.67%
-	0.0001	84.68%	60.25%	84.7%	84.68%	84.56%
✓	0.1	10.91%	230.88%	1.19%	10.91%	2.15%
✓	0.01	74.72%	75.5%	74.94%	74.72%	74.43%
✓	**0.001**	**88.64%**	**51.95%**	**88.85%**	**88.64%**	**88.62%**
✓	0.0001	86.24%	46.91%	86.28%	86.24%	86.19%

CNN model iz literature postiže tačnost od 88.64% i F1-score od 88.62%, dok model implementiran u ovom radu ostvaruje F1-score od približno 84%. Iako su rezultati nešto niži u odnosu na literaturu, odstupanje od oko 5 procentnih poena može se objasniti razlikama u arhitekturi, hiperparametrima i eksperimentalnom podešavanju.

Literatura

ZAKLJUČAK

Analiza performansi po klasama pokazala je da model najuspešnije prepoznaje žanrove sa izraženim i stabilnim spektralnim obrascima, poput Classical i Metal, dok su najveći izazovi uočeni kod žanrova Rock i Reggae, verovatno zbog stilskog preklapanja i sličnih akustičkih karakteristika sa drugim žanrovima.

Dobijeni rezultati potvrđuju da Mel spektrogrami sadrže bogate i informativne reprezentacije audio signala, pogodne za primenu konvolutivnih neuronskih mreža u zadacima klasifikacije muzike.