Klasifikacija muzike na osnovu žanra

Natalija Pavlićević 68/2022
Tamara Krstić 96/2022

Projekat u okviru kursa Računarska inteligencija
Mart 2026.

Sadržaj:

1. Uvod....3
1.1 Opis problema.... 3
1.2 Pregled literature i skupa podataka.... 3
2. Metodologija....4
2.1 Prvi pristup: Model višeslojnog perceptona.... 4
2.1 Drugi pristup: CNN nad mel-spektrogramima....5
3. Pretprocesiranje podataka....6
3.1 Učitavanje i normalizacija.... 6
3.2 Transformacija u frekventni domen i ekstrakcija obeležja.... 6
3.4 Standardizacija i oblikovanje ulaza....7
3.5 Vizualizacija audio signala....7
4. Ekstrakcija obeležja....10
4.1 Mel-Frequency Cepstral Coefficients (MFCC)....10
4.2 Parametri ekstrakcije....11
4.3 Formiranje ulaznog vektora.... 11
4.4 Spektrogram kao ulaz za CNN model (Napredni pristup)....12
5. Arhitektura i implementacija modela....12
5.1 Model višeslojnog perceptona.... 12
5.1.1 Kodiranje izlaznih klasa.... 13
5.1.2 Arhitektura modela....13
5.1.3 Obuka modela....14
5.2 Konvolutivna neuronska mreža (CNN).... 14
5.2.1 Arhitektura CNN modela....14
5.2.2 Regularizacija i robusnost....15
5.2.3 Obuka modela....15
6. Eksperimenti i rezultati.... 15
6.1 Rezultati MLP modela....16
6.2 Rezultati CNN modela.... 18
6.2 Rezultati CRNN modela iz literature....20
7. Zaključak.... 20
8. Literatura.... 21

1. Uvod

Automatska klasifikacija muzičkih žanrova predstavlja jedan od centralnih izazova u oblasti pronalaženja informacija iz audio zapisa. Sa eksponencijalnim rastom digitalnih muzičkih biblioteka i striming servisa poput Spotify-a i Tidal-a, potreba za preciznim algoritmima koji mogu automatski organizovati i preporučivati muziku postala je neophodna.

1.1 Opis problema

Problem klasifikacije žanrova je specifičan jer su granice između žanrova često subjektivne i prožimaju se. Za razliku od klasifikacije slika gde su objekti jasno definisani, muzički žanr je određen kombinacijom ritma, harmonije, instrumentacije i teksture zvuka. Cilj ovog rada je razvoj i evaluacija modela mašinskog učenja koji na osnovu digitalnog audio signala dodeljuje jednu od deset unapred definisanih kategorija (žanrova).

1.2 Pregled literature i skupa podataka

U ovom radu koristi se **GTZAN** skup podataka, koji se u naučnoj zajednici smatra "benchmark" skupom za ovu vrstu problema. Ovaj skup sadrži 1000 audio numera podeljenih u 10 žanrova (Blues, Classical, Country, Disco, Hiphop, Jazz, Metal, Pop, Reggae, Rock).

Rana istraživanja u ovoj oblasti fokusirala su se na ekstrakciju ručno definisanih karakteristika (eng. *hand-crafted features*) kao što su:

1. **Karakteristike vremenskog domena**
    - **Srednja kvadratna energija (RMSE):** određuje koliko je zvuk glasan
    - **Zero Crossing Rate (ZCR):** mera učestalosti promene znaka signala.
1. **Karakteristike frekventnog domena**
    - **Spectral Roloff:** mera oblika spektra frekvencija.

- **Mel-Frequency Cepstral Coefficients (MFCC):** koeficijenti koji predstavljaju kratkotrajni spektar snage zvuka na bazi nelinearne Mel skale, koja bolje simulira ljudski sluh.

Najnovija istraživanja, poput onog koje su sproveli Setiorini i saradnici (2025), ukazuju na to da kombinacija konvolutivnih i rekurentnih slojeva (CRNN) daje vrhunske rezultate na GTZAN skupu podataka [1]. Međutim, u ovom radu je fokus stavljen na bazni MLP model kako bi se ispitala linearna separabilnost MFCC obeležja pre primene kompleksnijih arhitektura. Pored toga, implementiran je i konvolucioni neuronski model (CNN) nad Mel-spektrogramima radi ispitivanja sposobnosti dubokih arhitektura da automatski ekstraktuju prostorno-vremenske karakteristike audio signala i unaprede performanse klasifikacije.

2. Metodologija

U ovom radu implementirana su dva pristupa klasifikaciji. Dok se bazni model fokusirao na statističke deskriptore MFCC koeficijenata, napredno rešenje koristi Konvolutivnu neuronsku mrežu (CNN) koja analizira celokupnu vremensko-frekvencijsku strukturu audio signala putem mel-spektrograma.

- **MLP model:** Izvršena je ekstrakcija 20 MFCC koeficijenata. Izračunata je njihova srednja vrednost i standardna devijacija, čime je svaki audio snimak sveden na vektor od 40 numeričkih vrednosti.
- **CNN model:** Generisani su dvodimenzionalni Mel-spektrogrami. Audio signal je pretvoren u sliku koja čuva frekvencijsku i vremensku strukturu, što omogućava mreži da uči audio obrasce (teksture) direktno sa slike.

2.1 Prvi pristup: Model višeslojnog perceptona

Celokupan tok obrade podataka sastoji se iz sledećih faza:

1. **Učitavanje i segmentacija audio zapisa:** Prikupljanje sirovih signala iz GTZAN skupa podataka.

2. **Pretprocesiranje signala:** Priprema audio zapisa za ekstrakciju karakteristika (učitavanje u odgovarajućem frekvencijskom opsegu).
3. **Ekstrakcija MFCC obeležja:** Izračunavanje 20 koeficijenata mel-frekvencijskih cepstara.
4. **Formiranje vektora karakteristika:** Izračunavanje aritmetičke sredine i standardne devijacije ekstrahovanih koeficijenata radi dobijanja statičkog ulaza od 40 dimenzija.
5. **Dizajn i obuka MLP klasifikatora:** Konfigurisanje potpuno povezane neuronske mreže i optimizacija njenih parametara nad trening skupom.
6. **Evaluacija modela:** Testiranje preciznosti i analiza rezultata pomoću matrice konfuzije i standardnih statističkih metrika.

Ulaz u sistem predstavlja sirovi audio signal, dok je izlaz diskretna oznaka žanra iz skupa od deset unapred definisanih kategorija. Fokus rada je na ispitivanju efikasnosti baznog MLP modela u odnosu na složenije arhitekture opisane u literaturi.

2.1 Drugi pristup: CNN nad mel-spektrogramima

Za razliku od prethodnog modela, ovaj pristup ne vrši agresivnu redukciju podataka na 40 brojeva, već tretira audio signal kao sliku (spektrogram).

- **Pretprocesiranje:** Umesto izračunavanja srednje vrednosti, generisan je kompletan mel-spektrogram koji čuva informaciju o tome kako se frekvencije menjaju kroz vreme.
- **Arhitektura:** Korišćena je konvolutivna mreža (CNN) koja je sposobna da automatski detektuje vizuelne obrasce (teksture) u spektrogramu karakteristične za određene žanrove.

Celokupan tok obrade podataka sastoji se iz sledećih faza:

1. **Generisanje Mel-spektrograma:** Transformacija sirovog audio signala u 2D vremensko-frekvencijsku reprezentaciju.

2. **Pretprocesiranje i normalizacija:** Skaliranje vrednosti spektrograma i prilagođavanje dimenzija (oblikovanje ulaznih tenzora).
3. **Definisanje arhitekture modela:** Dizajniranje slojeva robusne konvolutivne neuronske mreže (Conv2D, Batch Normalization, Pooling).
4. **Konfiguracija strategije obuke:** Odabir optimizatora, funkcije gubitka i parametara regularizacije (Dropout, Early Stopping).
5. **Obuka modela:** Proces optimizacije težina mreže nad trening i validacionim skupom podataka.
6. **Evaluacija i vizuelizacija:** Testiranje performansi modela nad neviđenim podacima i analiza kriva učenja (Accuracy/Loss grafikoni).

3. Pretprocesiranje podataka

Pre obuke modela mašinskog učenja neophodno je izvršiti adekvatnu obradu audio signala. Iako se MLP i CNN modeli razlikuju u arhitekturi, inicijalna obrada signala iz GTZAN skupa podataka prati zajedničke korake kako bi se obezbedila konzistentnost.

3.1 Učitavanje i normalizacija

Svi audio zapisi učitani su koristeći biblioteku Librosa uz fiksnu frekvenciju uzorkovanja od 22.050 Hz. Ova frekvencija predstavlja standard u obradi muzike i omogućava balans između kvaliteta reprezentacije i računarske efikasnosti.

Signal je zatim normalizovan kako bi se smanjio uticaj razlika u jačini zvuka između različitih numera. Normalizacija omogućava modelu da se fokusira na strukturne karakteristike signala umesto na apsolutnu amplitudu.

3.2 Transformacija u frekventni domen i ekstrakcija obeležja

U ovoj fazi, proces obrade se grana u zavisnosti od odabranog modela klasifikacije:

- **Za MLP model (Statistički pristup):** Signal je transformisan u MFCC koeficijente. Kako bi se vremenska serija svela na fiksni ulaz pogodan za MLP, izračunata je srednja vrednost i standardna devijacija za 20 koeficijenata, čime je dobijen vektor od 40 numeričkih obeležja.
- **Za CNN model (Spektrogramski pristup):** Umesto redukcije podataka na statističke deskriptore, generisani su kompletni Mel-spektrogrami. Ova 2D reprezentacija čuva celokupnu vremensko-frekvencijsku strukturu signala, tretirajući audio zapis kao sliku visoke rezolucije, što omogućava konvolutivnim slojevima da detektuju kompleksne teksturne obrasce žanra.

3.4 Standardizacija i oblikovanje ulaza

Standardizacija je primenjena na oba skupa podataka radi brže konvergencije gradijenta.

- **Kod MLP modela**, ulaz je jednodimenzionalni vektor.
- **Kod CNN modela**, podaci su oblikovani u trodimenzionalne tenzore (visina, širina, 1 kanal), čime je omogućeno konvolutivnim filterima da vrše prostornu ekstrakciju obeležja.

3.5 Vizualizacija audio signala

U okviru analize podataka izvršena je i vizualizacija audio signala u cilju boljeg razumevanja njihovih spektralnih karakteristika. Za ovu svrhu korišćeni su vremenski i vremensko-frekventni prikazi signala.

Waveform predstavlja prikaz amplitude audio signala kroz vreme i omogućava analizu dinamičkih promena zvuka. Mel spektrogram predstavlja vremensko-frekventnu reprezentaciju signala zasnovanu na Mel skali, koja modeluje nelinearnu percepciju frekvencija kod ljudskog sluha.

Vizualizacija je korišćena kao pomoćni alat za analizu razlika između muzičkih žanrova i za potvrdu spektralnih karakteristika relevantnih za klasifikaciju.

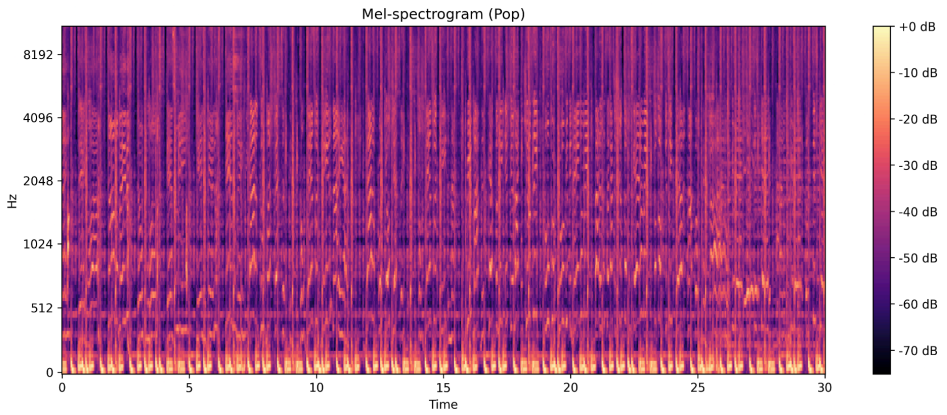

Slika 1: Mel spektogram pop pesme

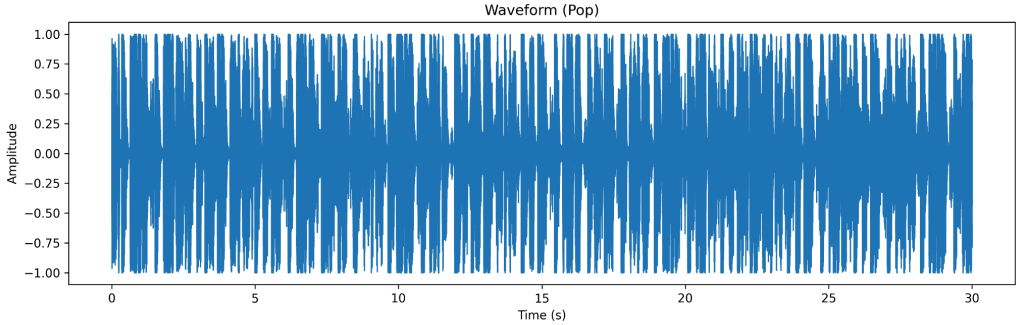

Slika 2: Waveform pop pesme

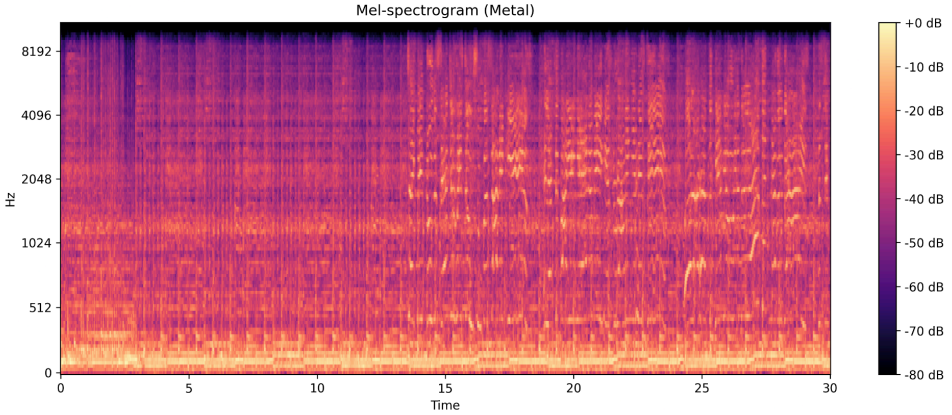

Slika 3: Mel spektogram metal pesme

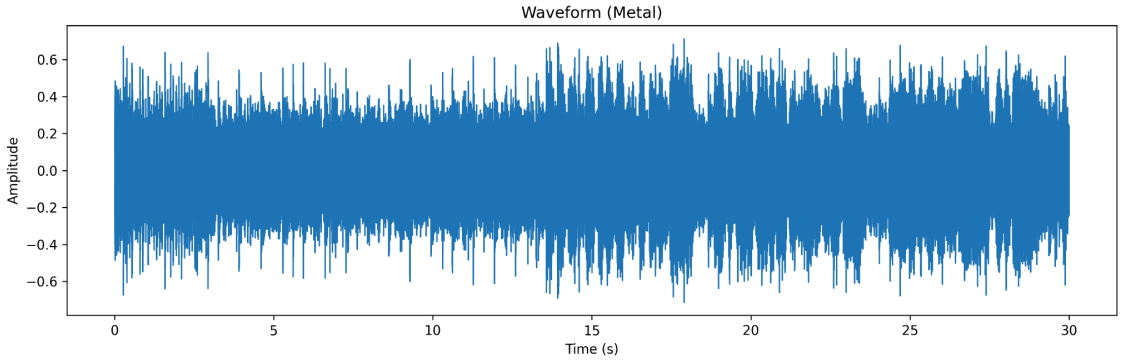

Slika 4: Waveform metal pesme

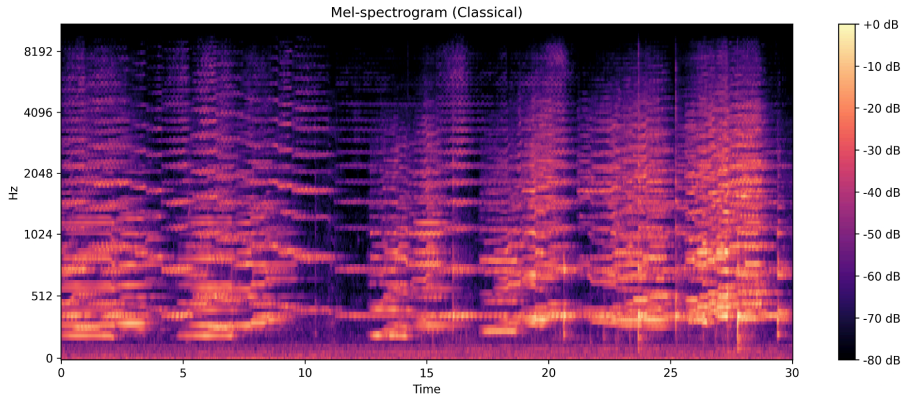

Slika 5: Mel spektogram klasične pesme

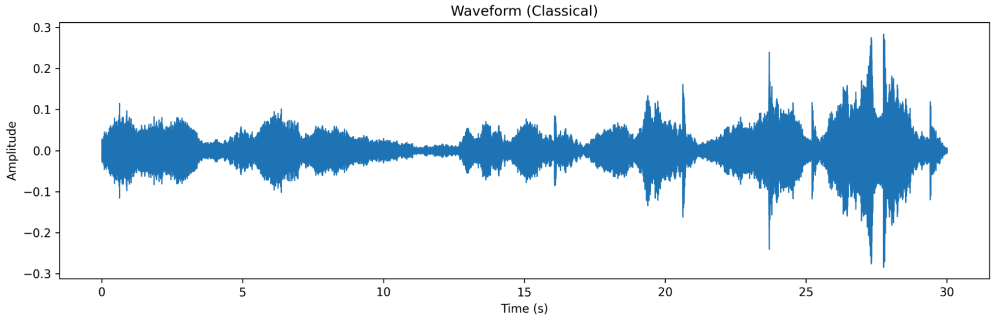

Slika 6: Waveform klasične pesme

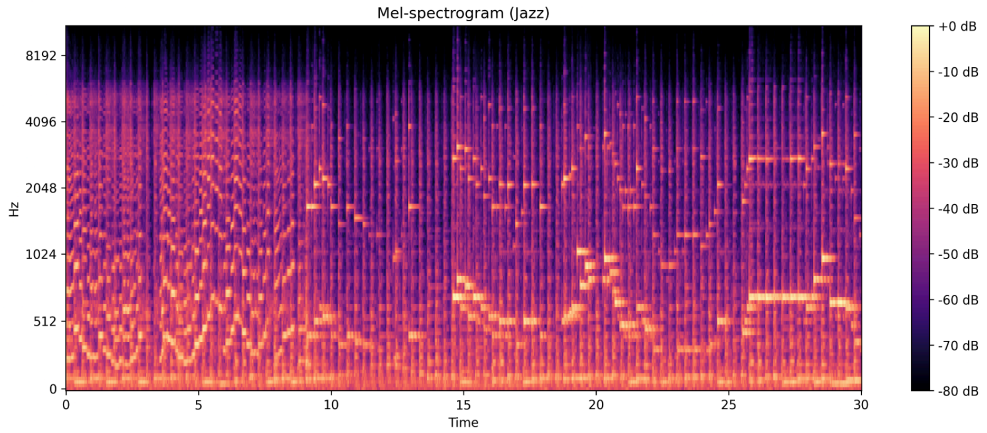

Slika 7: Mel spektogram džez pesme

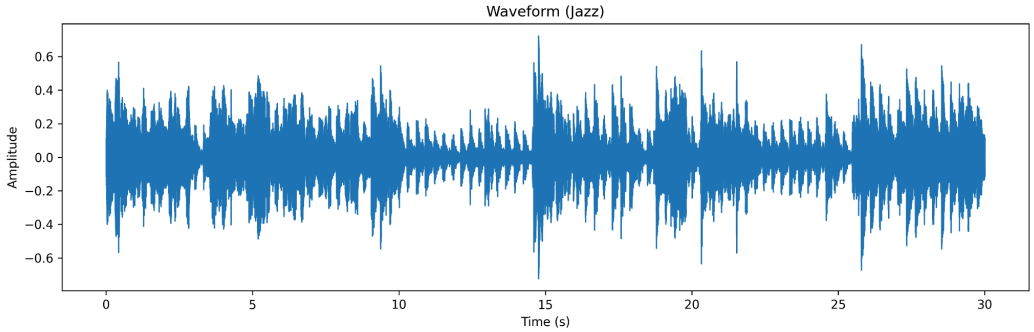

Slika 8: Waveform džez pesme

4. Ekstrakcija obeležja

Nakon faze pretprocesiranja, pristupa se ekstrakciji karakteristika. U ovom radu primenjuju se dva različita pristupa: statistička ekstrakcija MFCC obeležja (za MLP model) i očuvanje prostornih obeležja putem Mel-spektrograma (za CNN model).

4.1 Mel-Frequency Cepstral Coefficients (MFCC)

U ovom radu kao primarna obeležja koriste se Mel-frekventni cepstralni koeficijenti (MFCC). MFCC predstavljaju standard u oblasti analize audio signala, jer omogućavaju efikasno modelovanje perceptivnih karakteristika zvuka.

Proces izračunavanja MFCC obeležja sastoji se iz sledećih koraka:

1. Primena kratkotrajne Furijeove transformacije (STFT) nad segmentiranim signalom.
2. Mapiranje frekvencijskog spektra na Mel skalu pomoću Mel filter banke.
3. Logaritamska transformacija energije po filterima.
4. Diskretna kosinusna transformacija (DCT) radi dobijanja cepstralnih koeficijenata.

Mel skala modeluje nelinearnu percepciju frekvencija kod ljudskog sluha, pri čemu su niže frekvencije detaljnije reprezentovane u odnosu na više.

4.2 Parametri ekstrakcije

U implementaciji je korišćeno:

- Frekvencija uzorkovanja: 22.050 Hz
- Broj Mel filtera: 128
- Broj MFCC koeficijenata: 20

Svaki audio zapis rezultuje matricom dimenzija: $N_{frames} \times N_{MFCC}$

gde je N_{frames} broj vremenskih prozora, a N_{MFCC} broj izračunatih koeficijenata.

4.3 Formiranje ulaznog vektora

Pošto višeslojni perceptron (MLP) zahteva fiksnu dimenziju ulaza, izvršena je agregacija MFCC matrice po vremenskoj osi. Konkretno, za svaki koeficijent izračunate su:

- srednja vrednost
- standardna devijacija

Na taj način formiran je ulazni vektor dimenzije: $2 \times N_{MFCC}$

Ova redukcija omogućava zadržavanje globalnih spektralnih karakteristika uz značajno smanjenje dimenzionalnosti.

MFCC obeležja su odabrana iz sledećih razloga:

1. Dokazana efikasnost u klasifikaciji audio signala.
2. Biološka utemeljenost kroz Mel skalu.
3. Kompatibilnost sa jednostavnijim klasifikatorima poput MLP modela.
4. Upotreba u savremenim istraživanjima, uključujući rad Setiorini i saradnika (2025) [1].

Za razliku od dubokih konvolutivnih modela koji rade nad sirovim spektrogramima, pristup zasnovan na MFCC obeležjima omogućava analizu linearne separabilnosti klasa uz manju računarsku složenost.

4.4 Spektrogram kao ulaz za CNN model (Napredni pristup)

Za razliku od MLP modela koji koristi agregaciju (srednju vrednost i devijaciju), CNN model koristi sirovi Mel-spektrogram generisan u fazi 4.1 (pre DCT transformacije). Dok MFCC proces (tačka 4.1, korak 4) vrši kompresiju podataka radi jednostavnosti, za potrebe CNN modela zadržava se kompletna 2D matrica.

Razlog: Konvolutivni slojevi su dizajnirani da sami "ekstrahuju" obeležja iz slika, pa im je potreban bogatiji izvor informacija od samog 40-dimenzionalnog vektora.

5. Arhitektura i implementacija modela

5.1 Model višeslojnog perceptona

Za klasifikaciju muzičkih žanrova korišćen je višeslojni perceptron (MLP), koji predstavlja tip veštačke neuronske mreže zasnovane na potpuno povezanim (fully connected) slojevima. Ulaz u model čine ekstraktovana MFCC obeležja dimenzije $2 \times N_{MFCC}$, što u ovom radu predstavlja 40-dimenzionalni ulazni vektor.

Pre obuke modela izvršena je standardizacija ulaznih podataka korišćenjem Z-score normalizacije: $x' = (x - \mu)/\sigma$

Standardizacija je primenjena kako bi se ubrzala konvergencija modela i stabilizovao proces učenja.

5.1.1 Kodiranje izlaznih klasa

Pošto MLP zahteva numeričku reprezentaciju izlaznih kategorija, izvršeno je kodiranje oznaka žanrova korišćenjem one-hot reprezentacije. Ova transformacija omogućava da svaki žanr bude predstavljen kao vektor verovatnoća.

One-hot kodiranje transformiše kategorijske oznake u binarne vektore gde vrednost 1 označava pripadnost klasi, dok 0 označava odsustvo pripadnosti.

5.1.2 Arhitektura modela

Model se sastoji od četiri potpuno povezana sloja:

- Ulazni sloj
- Tri skrivena sloja sa ReLU aktivacionom funkcijom
- Izlazni sloj sa Softmax aktivacijom

ReLU funkcija definisana je kao: $f(x) = \max(0, x)$

Softmax funkcija koristi se na izlaznom sloju za izračunavanje verovatnoća pripadnosti svakoj klasi.

Model se sastoji od tri skrivena potpuno povezana sloja sa 128, 64 i 32 neurona, dok izlazni sloj sadrži onoliko neurona koliko postoji klasa u skupu podataka.

5.1.3 Obuka modela

Model je treniran korišćenjem Adam optimizatora i funkcije gubitka kategorijske unakrsne entropije (categorical crossentropy): $L=-\sum y \log(\hat{y})$

Model je treniran tokom 25 epoha sa veličinom batch-a od 32 uz korišćenje 10% trening podataka za validaciju.

5.2 Konvolutivna neuronska mreža (CNN)

Kao naprednije rešenje, implementirana je konvolutivna neuronska mreža (CNN). Za razliku od MLP modela koji obrađuje statičke vektore, CNN je dizajniran da direktno analizira dvodimenzionalne Mel-spektrograme, tretirajući ih kao slike koje sadrže bogate temporalne i frekvencijske informacije.

5.2.1 Arhitektura CNN modela

Model je zasnovan na hijerarhijskoj ekstrakciji obeležja kroz seriju konvolutivnih i pooling slojeva. Arhitektura se sastoji od:

- **Tri konvolutivna bloka:** Svaki blok sadrži Conv2D sloj (sa 32, 64 i 128 filtera respektivno) zadužen za detekciju lokalnih audio obrazaca.
- **Batch Normalization:** Primenjen nakon svake konvolucije radi stabilizacije internih distribucija i ubrzanja procesa učenja.
- **MaxPooling2D:** Vrši redukciju prostornih dimenzija (subsampling), čime se smanjuje broj parametara i povećava invarijantnost modela na male promene u vremenu.
- **GlobalAveragePooling2D:** Menja klasičan Flatten sloj, vršeći agregaciju informacija po celoj mapi obeležja, što značajno doprinosi smanjenju preprilagođavanja (overfitting).
- **Klasifikacioni deo:** Potpuno povezani sloj sa 128 neurona i izlazni sloj sa 10 neurona.

5.2.2 Regularizacija i robusnost

Kako bi se obezbedila visoka sposobnost generalizacije, u model su integrisane sledeće tehnike:

- **Dropout (0.4):** Nasumično isključivanje 40% neurona tokom treninga sprečava model da previše zavisi od specifičnih trening uzoraka.
- **Early Stopping:** Mehanizam koji prati gubitak na validacionom skupu (val_loss) i prekida obuku ako ne dođe do poboljšanja u roku od 10 epoha, vraćajući model na najbolje sačuvane težine.

5.2.3 Obuka modela

Model je treniran korišćenjem **Adam optimizatora** sa smanjenom stopom učenja (10^{-4}) kako bi se osigurala precizna konvergencija. Korišćena je funkcija gubitka *Sparse Categorical Crossentropy*, koja je pogodna za klasifikaciju gde su izlazne oznake celi brojevi. Maksimalni predviđeni broj epoha je 100, uz aktiviran Early Stopping mehanizam.

6. Eksperimenti i rezultati

U ovom poglavlju prikazani su rezultati klasifikacije dobijeni korišćenjem MLP i CNN modela.

U cilju evaluacije performansi predloženog sistema izvršeno je eksperimentalno testiranje modela na test skupu podataka. Podaci su podeljeni na trening i test skup u odnosu 80:20, uz dodatno izdvajanje 10% trening podataka za validaciju.

Performanse modela procenjene su korišćenjem metrike tačnosti (accuracy), odziva (recall) i f1-skora.

6.1 Rezultati MLP modela

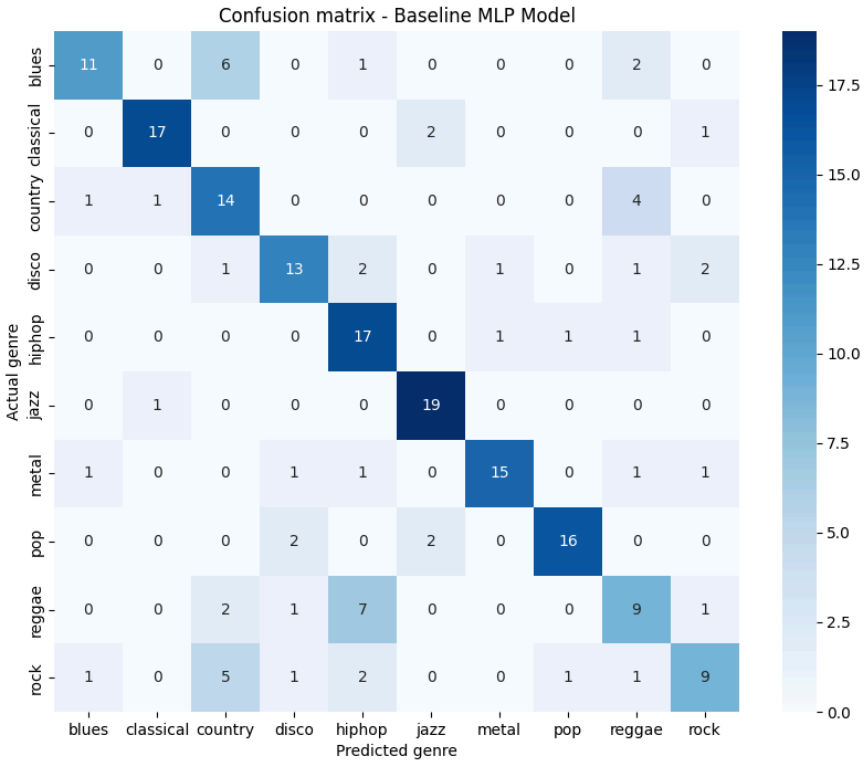

Slika 9: Matrica konfuzije MLP modela

žanr	**preciznost**	**odziv**	**f1-skor**
blues	0.79	0.55	0.65
classical	0.89	0.85	0.87
country	0.50	0.70	0.58
disco	0.72	0.65	0.68
hiphop	0.57	0.85	0.68
jazz	0.83	0.95	0.88
metal	0.88	0.75	0.81
pop	0.89	0.80	0.84

reggae	0.47	0.45	0.46
rock	0.64	0.45	0.53

Tabela 1: Detaljne metrike MLP modela

Tabela 1 prikazuje detaljne metrike: preciznost (precision), odziv (recall) i F1-skor za svaki od 10 žanrova.

Iz rezultata se jasno vidi da model nije podjednako uspešan za sve žanrove:

- **Najuspešniji žanrovi:** Model najbolje prepoznaje Jazz (F1-score: 0.88) i Classical (F1-score: 0.87). Ovo je očekivano, jer ovi žanrovi imaju veoma specifične i konzistentne spektralne karakteristike koje se jasno razlikuju od ostatka skupa.
- **Najveći izazovi:** Najslabije rezultate model postiže kod žanrova Reggae (0.46) i Rock (0.53).

Matrica konfuzije (Slika 9) pruža dublji uvid u greške modela.

Na osnovu matrice i izveštaja, mogu se izvući sledeći zaključci:

- **Sličnost instrumenata:** Niska preciznost kod žanra Reggae (0.47) često je posledica mešanja sa žanrovima poput Hiphop-a, jer dele slične ritmičke strukture koje MFCC koeficijenti, u obliku u kom su korišćeni (srednja vrednost), ponekad ne mogu da razluče.
- **Problem žanra Rock:** Rock muzika ima nizak odziv (recall) od samo 0.45, što znači da je model više od polovine pesama ovog žanra pogrešno klasifikovao u druge kategorije (najčešće Country).
- **Hiphop:** Primećuje se da model ima visok odziv za Hiphop (0.85), ali nisku preciznost (0.57), što znači da model "naginje" ka tome da mnoge pesme koje nisu hiphop klasifikuje u tu kategoriju.

6.2 Rezultati CNN modela

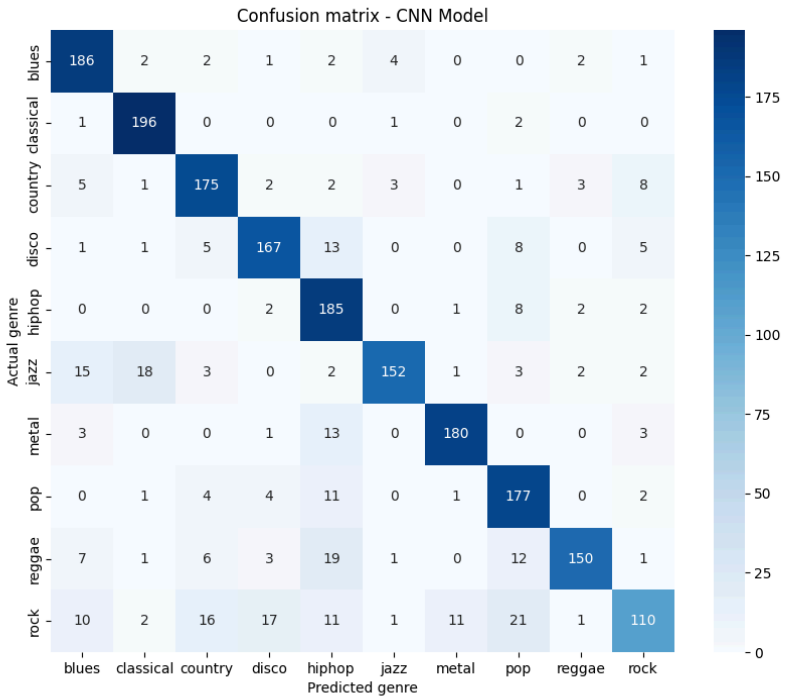

Slika 10: Matrica konfuzije CNN modela

žanr	**preciznost**	**odziv**	**f1-skor**
blues	0.82	0.93	0.87
classical	0.88	0.98	0.93
country	0.83	0.88	0.85
disco	0.85	0.83	0.84
hiphop	0.72	0.93	0.81
jazz	0.94	0.77	0.84
metal	0.93	0.90	0.91
pop	0.76	0.82	0.82
reggae	0.94	0.75	0.83

rock	0.82	0.55	0.66

Tabela 2: Detaljne metrike CNN modela

Rezultati po klasama pokazuju da CNN model ostvaruje visoke vrednosti precision, recall i F1-score za većinu žanrova, što potvrđuje da Mel spektrogrami sadrže dovoljno informacija za klasifikaciju muzičkih žanrova

Na osnovu Tabele 2 dolazimo do sledećih zaključaka:

- **Najuspešniji žanrovi:** Model najbolje prepoznaje Metal (F1-score: 0.91) i Classical (F1-score: 0.93). Ovo je očekivano, jer ovi žanrovi imaju veoma specifične i konzistentne spektralne karakteristike koje se jasno razlikuju od ostatka skupa. Visok recall kod klase Classical (0.98) ukazuje da model gotovo sve primere ovog žanra uspešno detektuje. Ovo je očekivano jer klasična muzika ima specifične i stabilne spektralne obrasce.
- **Klasa sa umerenim performansama:** Jazz ima visoku precision (0.94), ali niži recall (0.77). Model retko pogrešno označava druge žanrove kao jazz, ali deo jazz primera klasifikuje u srodne kategorije.
- **Najveći izazovi:** Najslabije rezultate model postiže kod žanra Rock (f1-skor 0.66, odziv: 0.55). Nizak odziv ukazuje na to da CNN model često klasifikuje rock pesme kao druge žanrove, verovatno zbog stilskog preklapanja sa metal, pop ili blues žanrovima.

Matrica konfuzije takođe pokazuje da postoji napredak u klasifikaciji pesama žanra blues.

.

6.2 Rezultati CRNN modela iz literature

Dropout	Learning rate	Accuracy	Loss	Precision	Recall	F1 score
-	0.1	10.06%	230.86%	1.01%	10.06%	1.84%
-	0.01	74.07%	91.52%	74.82%	74.07%	73.81%
-	0.001	86.74%	64.69%	86.84%	86.74%	86.67%
-	0.0001	84.68%	60.25%	84.7%	84.68%	84.56%
✓	0.1	10.91%	230.88%	1.19%	10.91%	2.15%
✓	0.01	74.72%	75.5%	74.94%	74.72%	74.43%
✓	**0.001**	**88.64%**	**51.95%**	**88.85%**	**88.64%**	**88.62%**
✓	0.0001	86.24%	46.91%	86.28%	86.24%	86.19%

Tabela 2: Detaljne metrike CRNN modela iz literature [1]

CNN model iz literature postiže tačnost od 88.64% i F1-score od 88.62%, dok model implementiran u ovom radu ostvaruje F1-score od približno 84%. Iako su rezultati nešto niži u odnosu na literaturu, odstupanje od oko 5 procentnih poena može se objasniti razlikama u arhitekturi, hiperparametrima i eksperimentalnom podešavanju. Rezultati potvrđuju da primenjeni pristup daje konkurentne performanse.

7. Zaključak

U ovom radu analizirana je primena metoda mašinskog učenja i dubokog učenja za klasifikaciju muzičkih žanrova na osnovu audio signala. Kao ulazne reprezentacije korišćeni su Mel-frekventni cepstralni koeficijenti (MFCC) i Mel spektrogrami, koji modeluju vremensko-frekventne karakteristike zvuka u skladu sa perceptivnim osobinama ljudskog sluha.

Implementirana su dva pristupa: višeslojni perceptron (MLP), koji koristi statistički agregirane MFCC koeficijente, i konvolutivna neuronska mreža (CNN), koja

direktno obrađuje dvodimenzionalne Mel spektrograme. Rezultati pokazuju da CNN model ostvaruje značajno bolje performanse u poređenju sa MLP modelom, što potvrđuje prednost hijerarhijske ekstrakcije obeležja kod dubokih neuronskih mreža.

Analiza performansi po klasama pokazala je da model najuspešnije prepoznaje žanrove sa izraženim i stabilnim spektralnim obrascima, poput Classical i Metal, dok su najveći izazovi uočeni kod žanrova Rock i Reggae, verovatno zbog stilskog preklapanja i sličnih akustičkih karakteristika sa drugim žanrovima.

Dobijeni rezultati potvrđuju da Mel spektrogrami sadrže bogate i informativne reprezentacije audio signala, pogodne za primenu konvolutivnih neuronskih mreža u zadacima klasifikacije muzike.

8. Literatura

[1] E. Setiorini *et al.*, "Reduced Convolutional Recurrent Neural Network Using MFCC for Music Genre Classification on the GTZAN Dataset," *Informatica*, vol. 49, no. 17, pp. 145–154, 2025. doi: 10.31449/inf.v49i17.6885

[2] M. S. Islam *et al.*, "Machine Learning-Based Music Genre Classification with PreProcessed Feature Analysis," *Jurnal Ilmiah Teknik Elektro Komputer dan Informatika (JITEKI)*, vol. 7, no. 3, pp. 491-502, Dec. 2021. doi: 10.26555/jiteki.v7i3.22327.